

データの内在次元を用いた拡散モデルの収束解析

枇榔 一真

大阪大学基礎工学研究科 M2

2026 年 8 月 20 日

目次

- 拡散モデルは、画像生成や動画生成など、データの生成を行うことのできるアルゴリズムであり、近年機械学習で盛んに研究が行われている。
- そのアルゴリズムは確率微分方程式 (SDE) でモデル化することができる。本発表では、**拡散モデルの収束解析**という、SDE の誤差の評価を行う問題について紹介する。

発表の流れ

- ① 拡散モデルについて
- ② 拡散モデルの収束解析について
- ③ 主結果
- ④ 設定
- ⑤ 証明概要

拡散モデルについて：生成とは

生成


未知の確率測度 P_{data} に従って独立に得られたデータ $\{x_1, \dots, x_n\} \subset \mathbb{R}^d$ があるとする。

このデータを用いて、 P_{data} に従う新たなデータを近似的に生み出すことを**生成**という。



生成モデル

生成を行う機械学習のモデルを、**生成モデル** という。




拡散モデルについて：SDEを用いた生成

$\{W_t\}_{t \in [0, T]}$ をブラウン運動として、次の SDE を考える。

$$dY_t = b(t, Y_t)dt + \sigma(t, Y_t)dW_t \quad (t \in [0, T])$$

上記の SDE の解 $\{Y_t\}_{t \in [0, T]}$ が次の 2 つの性質を満たすように、 b と σ を設計できるかということを考える。

- ① 初期分布 $\mathcal{L}(Y_0)$ が、容易にサンプルが得られる分布である (正規分布, 一様分布など)
- ② 最終時刻の分布が P_{data} と等しい. つまり, $\mathcal{L}(Y_T) = P_{\text{data}}$.



拡散モデルについて : Ornstein Uhlenbeck process

Ornstein Uhlenbeck process

次の SDE の解 $\{X_t\}_{t \in [0, T]}$ を Ornstein Uhlenbeck process という.


$$dX_t = -X_t dt + \sqrt{2} dW_t \quad (t \in [0, T])$$

上の SDE は明示的に解くことができ, X_0 と独立な標準正規分布に従う確率変数 Z が存在して,

$$X_t = e^{-t} X_0 + \sqrt{2} \int_0^t e^{-(t-s)} dW_s = e^{-t} X_0 + \sqrt{1 - e^{-2t}} Z$$

と書ける. これにより, T を十分大きくとると X_T の分布は標準正規分布 $\mathcal{N}(0, I_d)$ に近づいていく.

$\mathcal{L}(X_0) = P_{\text{data}}$ とすると, X は P_{data} から時間経過とともに $\mathcal{N}(0, I)$ へ近づいていく過程とみなせる.



拡散モデルについて：拡散過程の時間反転公式


定理 (Anderson 1982; Haussmann and Pardoux 1986)

X_t の密度を p_t とし, $\{Y_t\}_{t \in [0, T]}$ を次の SDE の解とする.

$$\begin{cases} dY_t = (Y_t + 2\nabla \log p_{T-t}(Y_t))dt + \sqrt{2}dW_t & (0 < t < T) \\ Y_0 \stackrel{d}{=} X_T \end{cases} \quad (1)$$

このとき, 任意の $t \in [0, T]$ に対して, $Y_t \stackrel{d}{=} X_{T-t}$ が成り立つ. 特に, $Y_t = X_{T-t}$ とすると $\{Y_t\}_{t \in [0, T]}$ は (1) の弱解となる.

$\{X_t\}_{t \in [0, T]}$ の時間反転過程 $\{Y_t\}_{t \in [0, T]}$ は, $\mathcal{L}(X_T) \approx \mathcal{N}(0, I_d)$ から時間の経過とともに P_{data} へ近づいていく確率過程となる.



拡散モデルについて：3つの誤差の発生源

$$\begin{cases} dY_t = (Y_t + 2\nabla \log p_{T-t}(Y_t))dt + \sqrt{2}dB_t & (0 \leq t \leq T) \\ Y_0 \stackrel{d}{=} X_T \approx \mathcal{N}(0, I_d) \end{cases}$$

上記の SDE をシミュレーションするには、いくつかの問題点が存在する。

問題点

- ① 初期分布 $\mathcal{L}(X_T)$ からの厳密なサンプリングが得られない。
- ② スコア関数 $\nabla \log p_{T-t}(Y_t)$ が明示的に得られない。
- ③ SDE を連続時間でシミュレーションできない。

対応方法

- ① 初期分布を標準正規分布 $\mathcal{N}(0, I_d)$ にする。
- ② スコア関数 $\nabla \log p_t(y)$ を推定量 $\hat{s}(t, y)$ に置き換える。
- ③ 時間に関して離散化する。

拡散モデルの収束解析について

実際にシミュレーションして得られるデータの分布を $\hat{P}_{\text{data}}$ とする. このとき, 確率測度の近さを測る指標 ρ を用いて, $\rho(P_{\text{data}}, \hat{P}_{\text{data}})$ を評価することを, **拡散モデルの収束解析** と呼ぶ.

指標 ρ として用いられるものは, 主に次の2種類である.

確率測度の評価指標

① Kullback-Leibler divergence

- 距離の公理は満たさないが, 広く用いられている指標

② 2-Wasserstein distance

- 距離の公理を満たす.
- 拡散モデルの収束解析においては, Kullback-Leibler divergence よりも解析が困難である場合が多い.

拡散モデルの収束解析について : Kullback-Leibler divergence

定義

2つの確率測度 P, Q の Kullback-Leibler divergence $D_{\text{KL}}(P|Q)$ を, 次のように定義する.

$$D_{\text{KL}}(P | Q) := \begin{cases} \mathbb{E}_P \left[\log \frac{dP}{dQ} \right] & (P \ll Q) \\ \infty & (\text{otherwise}) \end{cases}$$

定理 (Benton et al. 2024)

ある定数 $C > 0$ が存在して, 次の不等式が成立する.

$$D_{\text{KL}}(P_{\text{data}} | \hat{P}_{\text{data}}) \leq C \left(\underbrace{\frac{dT^2}{N}}_{\text{離散化誤差}} + \underbrace{\epsilon_{\text{score}}}_{\text{スコア推定誤差}} + \underbrace{(d + \mathbb{E}[\|X_0\|_2^2]) e^{-2T}}_{\text{初期分布誤差}} \right)$$

$$t_n = \frac{nT}{N} \quad (n = 0, \dots, N) \quad \epsilon_{\text{score}} = \frac{T}{N} \sum_{n=1}^N \mathbb{E} \left[\|\nabla \log p_{t_n}(X_{t_n}) - \hat{s}(t_n, X_{t_n})\|^2 \right]$$

N : 時間離散化のステップ数 d : データの次元 T : SDE の終端時刻

拡散モデルの収束解析について : Wasserstein distance

定義

$\mathbb{R}^d$ 上の確率測度 P, Q は有限な 2 次モーメントをもつとし,
 $\Pi(P, Q) = \{\pi : \mathbb{R}^d \times \mathbb{R}^d \text{ 上の確率測度} \mid \pi(\cdot, \mathbb{R}^d) = P, \pi(\mathbb{R}^d, \cdot) = Q\}$ とする. このとき, P, Q の 2-Wasserstein distance $W_2(P, Q)$ を次のように定義する.

$$W_2(P, Q) = \inf_{\pi \in \Pi(P, Q)} \left(\int_{\mathbb{R}^d \times \mathbb{R}^d} |x - y|^2 d\pi(x, y) \right)^{\frac{1}{2}}.$$

定理 (Koike 2026)


$t_n = \frac{nT}{N}$ ($n = 0, \dots, N$) とする. 適切な正則性条件のもとで, ある定数 $C_L > 0$ が存在して, 次の不等式が成立する.

$$W_2(P_{data}, \hat{P}_{data}) \leq C_L \left(\underbrace{\frac{\sqrt{d}T}{N}}_{\text{離散化誤差}} + \underbrace{\sqrt{\epsilon_{\text{score}}}}_{\text{スコア推定誤差}} + \underbrace{e^{-T} \left(\sqrt{\mathbb{E}[\|X_0\|_2^2]} + e^{-T}\sqrt{d} \right)}_{\text{初期分布誤差}} \right).$$

N : 時間離散化のステップ数 d : データの次元 T : SDE の終端時刻

拡散モデルの収束解析について：データの内在次元

現実世界のデータ分布はごく少数の変数で記述され则认为られている。これは**多様体仮説**と呼ばれ、機械学習の成功の基盤と被认为られている (Pope et al. 2021)。



データ分布を記述する上で必要な変数の数を、データ分布の**内在次元**と呼ぶ。

Pope et al. 2021 は、代表的な画像のデータセットに対する内在次元推定を行い、画像は $224 \times 224 \times 3 = 150528$ の画素値を持つが、内在次元は 26 ~ 43 程度であるという結果を得ている。

拡散モデルの収束解析について：データの内在次元

データの次元 d ではなく、内在次元 k を使った収束解析は Kullback-Leibler divergence において行われており、以下の結果が得られている。

定理 (Huang et al. 2026)

$t_n = \frac{nT}{N}$ ($n = 0, \dots, N$) とする。内在次元に対する適切な仮定のもと、ある定数 $C > 0$ が存在して、次の不等式が成立する。

$$KL(P_{data} \mid \hat{P}_{data}) \leq C \left(\underbrace{\frac{T^2}{N} k \log k}_{\text{離散化誤差}} + \underbrace{\epsilon_{score}}_{\text{スコア推定誤差}} + \underbrace{(d + \mathbb{E}[\|X_0\|_2^2]) e^{-2T}}_{\text{初期分布誤差}} \right).$$

N : 時間離散化のステップ数 d : データの次元 T : SDE の終端時刻 k : 内在次元

主結果

	KL divergence	2-Wasserstein distance
d 次元	$\lesssim \frac{dT^2}{N} + \epsilon_{\text{score}} + de^{-2T}$ Benton et al. (2024)	$\lesssim \frac{\sqrt{d} T}{N} + \sqrt{\epsilon_{\text{score}}} + \sqrt{d} e^{-2T}$ Koike (2026)
k 次元	$\lesssim \frac{T^2}{N} k \log k + \epsilon_{\text{score}} + de^{-2T}$ Huang et al. (2026)	$\lesssim \sqrt{\frac{Tk \log k}{N}} + \sqrt{\epsilon_{\text{score}}} + \sqrt{d} e^{-2T}$ 本研究

N : 時間離散化のステップ数, d : データの次元, k : 内在次元,
 T : SDE の終端時刻, ϵ_{score} : スコア推定誤差.

主結果：定理

定理

$t_n = \frac{nT}{N}$ ($n = 0, \dots, N$) とする. このとき, 正則性条件と, 内在次元に対する適切な仮定のもと, ある定数 $C > 0$ が存在して, 次が成立する.

$$W_2(P_{data}, \hat{P}_{data}) \leq C \left(\underbrace{\sqrt{\frac{Tk \log k}{N}}}_{\text{離散化誤差}} + \underbrace{\sqrt{\epsilon_{score}}}_{\text{スコア推定誤差}} + e^{-T} \underbrace{\left(\sqrt{\mathbb{E}[\|X_0\|_2^2]} + e^{-T} \sqrt{d} \right)}_{\text{初期分布誤差}} \right)$$

N : 時間離散化のステップ数 d : データの次元 T : SDE の終端時刻 k : 内在次元

設定：データの内在次元の仮定

定義

$A \subset \mathbb{R}^d$ に対する, スケール ϵ_0 における **covering number** $N_{\text{cover}}(A, \|\cdot\|_2, \epsilon_0)$ を, 次の関係を満たす $x_1, \dots, x_s \in \mathbb{R}^d$ が存在するような最小の自然数 s として定義する.

$$A \subset \bigcup_{i=1}^s B(x_i, \epsilon_0)$$

また, $\log N_{\text{cover}}(A, \|\cdot\|_2, \epsilon_0)$ を **metric entropy** という.

例

- k 次元単位球 $B^k = \{x \in \mathbb{R}^k : \|x\| \leq 1\}$ に対して, $0 < \epsilon_0 < 1$ のとき,

$$k \log \frac{1}{\epsilon_0} \leq \log N_{\text{cover}}(B^k, \|\cdot\|_2, \epsilon_0) \leq k \log \left(1 + \frac{2}{\epsilon_0}\right).$$

- k 次元線形部分空間内の有界集合 $A \subset B(0, R)$ に対して,

$$\log N_{\text{cover}}(A, \|\cdot\|_2, \epsilon_0) \leq k \log \left(1 + \frac{2R}{\epsilon_0}\right).$$

設定：データの内在次元の仮定

P_{data} のサポートを χ_{data} とする. χ_{data} に対して, 次の2つの仮定を置く.

仮定

$C_0 > 0$ を十分大きな定数とする. $\epsilon_0 = k^{-C_0}$ に対して, ある $C_{cover} > 0$ が存在して,

$$\log N_{cover}(\chi_{data}, |||_2, \epsilon_0) \leq C_{cover} k \log \frac{1}{\epsilon_0} \quad (2)$$

を満たすと仮定する. このとき k を χ_{data} の**内在次元**という.

仮定

ある定数 $C_R > 0$ が存在して, 次が成立すると仮定する.

$$\sup_{x \in \chi_{data}} \|x\|_2 \leq k^{C_R} \quad (3)$$

設定：SDE の書き換え

ある $Z \sim \mathcal{N}(0, I_d)$, $Z \perp X_0$ が存在して $X_t = e^{-t}X_0 + \sqrt{1 - e^{-2t}}Z$ と書けることから, Tweedie の公式により,

$$\nabla \log p_t(x) = \frac{e^{-t}\mathbb{E}[X_0 \mid X_t = x] - x}{1 - e^{-2t}}$$

の関係が成り立つ. いま, $Y_t = X_{T-t}$ ($t \in [0, T]$) とすると,

$$\begin{aligned}\nabla \log p_{T-t}(y) &= \frac{e^{-(T-t)}\mathbb{E}[X_0 \mid X_{T-t} = y] - y}{1 - e^{-2(T-t)}} \\ &= \frac{e^{-(T-t)}\mathbb{E}[Y_T \mid Y_t = y] - y}{1 - e^{-2(T-t)}}\end{aligned}$$

となる. よって, $\{Y_t\}_{t \in [0, T]}$ が従う SDE は次のように書き換えられる.

$$\begin{cases} dY_t = \left\{ \left(1 - \frac{2}{1 - e^{-2(T-t)}} \right) Y_t + \frac{2e^{-(T-t)}}{1 - e^{-2(T-t)}} \mathbb{E}[Y_T \mid Y_t] \right\} dt + \sqrt{2} dW_t \\ Y_0 \stackrel{d}{=} X_T \end{cases}$$

設定：実際にシミュレーションする SDE

Tweedie の公式

$$\mathbb{E}[Y_T \mid Y_t = y] = e^{T-t} \left\{ y + (1 - e^{-2(T-t)}) \nabla \log p_{T-t}(y) \right\}$$

に対して, スコア関数を推定量に置き換えたものを

$$\hat{\mu}_t(y) = e^t \left\{ y + (1 - e^{-2t}) \hat{s}(t, y) \right\}$$

と書く. $\{Y_t\}_{t \in [0, T]}$ が従う SDE

$$\begin{cases} dY_t = \left\{ \left(1 - \frac{2}{1 - e^{-2(T-t)}} \right) Y_t + \frac{2e^{-(T-t)}}{1 - e^{-2(T-t)}} \mathbb{E}[Y_T \mid Y_t] \right\} dt + \sqrt{2} dW_t \\ Y_0 = X_T = e^{-T} X_0 + \sqrt{1 - e^{-2T}} Z \end{cases}$$

に対して, 実際にシミュレーションするアルゴリズムを連続時間で補完した SDE を次のようにとる. ($t \in [t_n, t_{n+1}]$, $n = 0, \dots, N-1$).

$$\begin{cases} d\hat{Y}_t = \left\{ \left(1 - \frac{2}{1 - e^{-2(T-t)}} \right) \hat{Y}_t + \frac{2e^{-(T-t)}}{1 - e^{-2(T-t)}} \hat{\mu}_{T-t_n}(\hat{Y}_{t_n}) \right\} dt + \sqrt{2} dW_t \\ \hat{Y}_0 = Z \sim \mathcal{N}(0, I_d) \end{cases}$$

証明の概要：誤差の分解

前頁の確率過程 $Y, \hat{Y}$ に対して, Wasserstein distance の定義から,

$$W_2(P_{\text{data}}, \hat{P}_{\text{data}}) \leq \mathbb{E} \left[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2 \right]^{\frac{1}{2}}.$$

となる. これに対して適切に三角不等式や Gronwall 型の不等式を用いると, ある定数 $C_1 > 0$ が存在して次のように誤差を分解できる.

$$\begin{aligned} & \mathbb{E} \left[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2 \right]^{\frac{1}{2}} \\ & \leq C_1 \underbrace{\left[\mathbb{E} \left[\|Y_0 - \hat{Y}_0\|_2^2 \right]^{\frac{1}{2}} \right]}_{\text{初期分布誤差}} + \underbrace{\left(\sum_{n=0}^{N-1} \int_{t_n}^{t_{n+1}} \frac{e^{-2(T-t)}}{(1 - e^{-2(T-t)})^2} \right.}_{\text{離散化誤差}} \\ & \quad \left. \times \mathbb{E} \left[\|\mathbb{E}[Y_T | Y_t] - \mathbb{E}[Y_T | Y_{t_n}]\|_2^2 \right] dt \right)^{\frac{1}{2}} \\ & \quad + \underbrace{\left(\frac{T}{N} \sum_{n=1}^N \mathbb{E} \left[\|\nabla \log p_{t_n}(X_{t_n}) - \hat{s}(t_n, X_{t_n})\|^2 \right] \right)^{\frac{1}{2}}}_{\text{スコア推定誤差}} \end{aligned}$$

証明の概要：初期分布誤差, スコア推定誤差を評価

初期分布の取り方より,

$$\begin{aligned}\mathbb{E} \left[\left| Y_0 - \hat{Y}_0 \right|^2 \right] &= \mathbb{E} \left[\left\| e^{-T} X_0 + \sqrt{1 - e^{-2T}} Z - Z \right\|^2 \right] \\ &= e^{-2T} \mathbb{E} \left[\|X_0\|^2 \right] + (1 - \sqrt{1 - e^{-2T}})^2 d \\ &\leq e^{-2T} \mathbb{E} \left[\|X_0\|^2 \right] + e^{-4T} d\end{aligned}$$

と評価ができる. また, 仮定より,

$$\left(\frac{T}{N} \sum_{n=1}^N \mathbb{E} \left[\left\| \nabla \log p_{t_n}(X_{t_n}) - \hat{s}(t_n, X_{t_n}) \right\|^2 \right] \right)^{\frac{1}{2}} = \sqrt{\epsilon_{\text{score}}}$$

と評価できる.

証明の概要：離散化誤差を評価

補題

$$\begin{aligned} & \mathbb{E} [\|\mathbb{E}[Y_T | Y_t] - \mathbb{E}[Y_T | Y_s]\|_2^2] \\ &= \mathbb{E} [\text{Tr}(\text{Cov}(Y_T | Y_s))] - \mathbb{E} [\text{Tr}(\text{Cov}(Y_T | Y_t))]. \end{aligned}$$

この補題により、離散化誤差は次のように変形できる。

$$\begin{aligned} & \sum_{n=0}^{N-1} \int_{t_n}^{t_{n+1}} \frac{e^{-2(T-t)}}{(1 - e^{-2(T-t)})^2} \mathbb{E} [\|\mathbb{E}[Y_T | Y_t] - \mathbb{E}[Y_T | Y_{t_n}]\|_2^2] dt \\ &= \sum_{n=0}^{N-1} \int_{t_n}^{t_{n+1}} \frac{e^{-2(T-t)}}{(1 - e^{-2(T-t)})^2} \left(\mathbb{E} [\text{Tr}(\text{Cov}(Y_T | Y_{t_n}))] \right. \\ & \quad \left. - \mathbb{E} [\text{Tr}(\text{Cov}(Y_T | Y_t))] \right) dt \end{aligned}$$

証明の概要：離散化誤差を評価

補題

ある定数 $C_2 > 0$ が存在して,

$$\begin{aligned} & \sum_{n=0}^{N-1} \int_{t_n}^{t_{n+1}} \frac{e^{-2(T-t)}}{(1 - e^{-2(T-t)})^2} \\ & \quad \times \left(\mathbb{E} [\text{Tr} (\text{Cov} (Y_T \mid Y_{t_n}))] - \mathbb{E} [\text{Tr} (\text{Cov} (Y_T \mid Y_t))] \right) dt \\ & \leq C_2 \frac{T}{N} \log N_{\text{cover}} \left(\chi_{\text{data}}, \|\cdot\|_2, k^{-C_0} \right). \end{aligned}$$

また, 仮定よりある定数 $C_3 > 0$ が存在して,

$$C_2 \frac{T}{N} \log N_{\text{cover}} \left(\chi_{\text{data}}, \|\cdot\|_2, k^{-C_0} \right) \leq \frac{T}{N} C_3 k \log k$$

となる.

証明の概要：最後の評価

前頁までの評価をまとめると,

$$W_2(P_{\text{data}}, \hat{P}_{\text{data}}) \leq C \left(\underbrace{\sqrt{\frac{Tk \log k}{N}}}_{\text{離散化誤差}} + \underbrace{\sqrt{\epsilon_{\text{score}}}}_{\text{スコア推定誤差}} \right. \\ \left. + \underbrace{e^{-T} \left(\sqrt{\mathbb{E}[\|X_0\|_2^2]} + e^{-T} \sqrt{d} \right)}_{\text{初期分布誤差}} \right)$$

が得られる.

まとめ, 今後の展望

まとめ

- 拡散モデルはデータ生成を行えるアルゴリズムであり, SDE を用いて性能保証を行うことができる.
- SDE の離散化誤差はデータの次元 d ではなく, 内在次元 k を用いて評価することができる.

今後の展望

- 応用においては条件付き拡散モデルが重要なので, その理論解析にも取り組みたい.

参考文献 I

- Anderson, B. D. O. (1982). Reverse-time diffusion equation models. *Stochastic Processes and their Applications* 12, 313–326.
<https://mathscinet.ams.org/mathscinet/article?mr=656280>
- Hausmann, U. G. and Pardoux, E. (1986). Time reversal of diffusions. *The Annals of Probability* 14, 1188–1205.
<https://mathscinet.ams.org/mathscinet/article?mr=866342>
- Benton, J., De Bortoli, V., Doucet, A. and Deligiannidis, G. (2024). Nearly d -linear convergence bounds for diffusion models via stochastic localization. In *International Conference on Learning Representations*.
https://proceedings.iclr.cc/paper_files/paper/2024/hash/9edce07129d2ec4c511a8783eb3d81b5-Abstract-Conference.html
- Koike, Y. (2026). Wasserstein bounds for denoising diffusion probabilistic models via the Föllmer process. arXiv preprint arXiv:2605.18069.
<https://arxiv.org/abs/2605.18069>

参考文献 II

- Huang, Z., Wei, Y. and Chen, Y. (2024; revised 2026). Denoising diffusion probabilistic models are optimally adaptive to unknown low dimensionality. <https://arxiv.org/abs/2410.18784>
- Arsenyan, V., Vardanyan, E. and Dalalyan, A. S. (2025). Assessing the quality of denoising diffusion models in Wasserstein distance: noisy score and optimal bounds. In *Advances in Neural Information Processing Systems 38*. https://proceedings.neurips.cc/paper_files/paper/2025/hash/1c26c389d60ec419fd24b5fee5b35796-Abstract-Conference.html
- Pope, P., Zhu, C., Abdelkader, A., Goldblum, M. and Goldstein, T. (2021). The intrinsic dimension of images and its impact on learning. In *International Conference on Learning Representations*. <https://openreview.net/forum?id=XJk19XzGq2J>

Appendix : Tweedie の公式

定理 (Tweedie の公式)

X を $\mathbb{R}^d$ 値の任意の確率変数とし, $Z \sim \mathcal{N}(0, I_d)$ を X と独立とする. この時, $Y = X + \sqrt{t}Z$ として, Y の密度関数を p とすると, 次の関係が成り立つ.

$$\mathbb{E}[X \mid Y = y] = y + t \nabla \log p(y)$$

ある $Z \sim \mathcal{N}(0, I_d)$, $Z \perp X_0$ が存在して $X_t = e^{-t}X_0 + \sqrt{1 - e^{-2t}}Z$ と書けることから, Tweedie の公式により

$$e^{-t} \mathbb{E}[X_0 \mid X_t = x] = x + (1 - e^{-2t}) \nabla \log p_t(x)$$

となる. よって,

$$\nabla \log p_t(x) = \frac{e^{-t} \mathbb{E}[X_0 \mid X_t = x] - x}{1 - e^{-2t}}$$

となる.

Appendix : デノイジング・スコアマッチング

$X_0 \sim P_{\text{data}}, Z \sim \mathcal{N}(0, I_d)$ に対して

$$X_t = e^{-t} X_0 + \sqrt{1 - e^{-2t}} Z$$

とおく. Tweedie の公式より

$$\mathbb{E} \left[-\frac{Z}{\sqrt{1 - e^{-2t}}} \middle| X_t \right] = \nabla \log p_t(X_t)$$

が成り立つ. 2つの目的関数は

$$L_{\text{SM}}(\theta) := \mathbb{E} \left[\|s_\theta(t, X_t) - \nabla \log p_t(X_t)\|_2^2 \right],$$

$$L_{\text{DSM}}(\theta) := \mathbb{E} \left[\left\| s_\theta(t, X_t) + \frac{Z}{\sqrt{1 - e^{-2t}}} \right\|_2^2 \right]$$

である. ここで $s_\theta + \frac{Z}{\sqrt{1 - e^{-2t}}} = (s_\theta - \nabla \log p_t) + (\nabla \log p_t + \frac{Z}{\sqrt{1 - e^{-2t}}})$ と分解する. 上の関係から $\mathbb{E}[\nabla \log p_t(X_t) + \frac{Z}{\sqrt{1 - e^{-2t}}} \mid X_t] = 0$ なので, 交差項の期待値は 0 となる. よって,

$$L_{\text{DSM}}(\theta) = L_{\text{SM}}(\theta) + \mathbb{E} \left[\lambda(t) \left\| \nabla \log p_t(X_t) + \frac{Z}{\sqrt{1 - e^{-2t}}} \right\|_2^2 \right]$$

を得る. 右辺第 2 項は θ に依存しないので, 2つの目的関数は最小化問題として等価である.