

データの内在次元を考慮した Wasserstein 距離での拡散モデルの収束解析

枇榔 一真

関根・深澤・矢野 研究室

2026 年 7 月 13 日

目次

- 先行研究紹介
 - 拡散モデルの収束解析について
 - 評価指標の比較
 - データの内在次元について
 - 内在次元を用いた拡散モデルの収束解析について
- 設定
 - 拡散モデルの更新則
 - SDE を通じた解釈
 - Tweedie の公式
 - データの内在次元の仮定について
 - スコア関数に対する仮定
- 定理
- 定理の証明概要

拡散モデルの収束解析について

- 拡散モデルは, 未知の確率測度 p_{data} に従って独立に得られるデータ $x_1, \dots, x_n$ を用いて p_{data} に従うデータを新たに近似的に生み出す手法である.
- 近似的に生み出すデータが従う確率測度を $\hat{p}$ とした時に, 何かしらの確率測度の評価指標 ρ を用いて $\rho(p_{data}, \hat{p})$ を評価することが収束解析の主な目的である.
- 先行研究では, 評価指標 ρ として主に KL ダイバージェンスと 2-Wasserstein 距離が用いられている.(KL ダイバージェンスは距離の公理は満たさないがよく用いられている)

拡散モデルの収束解析について：KL ダイバージェンス

- KL での収束解析は (Benton et al. 2024; Chen et al. 2023a,b; Koike 2026) など多くの先行研究がある.
- データは $\mathbb{R}^d$ 上に分布するとしたとき, (Benton et al. 2024) では $KL(p_{data}, \hat{p}) \leq O(d)$ の評価が得られており, これは最適なオーダーであることが示されている.
- この結果は, p_{data} に関する一般的な仮定のもとで得られている.

拡散モデルの収束解析について：2-Wasserstein 距離

- 2-Wasserstein 距離での収束解析も近年増加している (Arsenyan et al. 2025; Beyler and Bach 2025; Bruno and Sabanis 2025; Gao et al. 2025) .
- 先行研究ではすでに $W_2(p_{data}, \hat{p}) \leq O(\sqrt{d})$ の評価が得られており、これも最適なオーダーであることが示されている。
- しかし、これらの先行研究ではデータ分布 p_{data} への log-concave 性など、一般的ではない仮定が置かれており、KL と比較して発展途上である。

評価指標の比較

- KL ダイバージェンス
 - ギルザノフの定理を使うことで容易に評価が可能であり, 一般的な仮定のもとで最適と思われるオーダー評価ができています.
 - KL ダイバージェンスが近くても平均や共分散が近いとは限らないなどの問題点がある (Beyler and Bach 2025).
- 2-Wasserstein 距離
 - 画像生成の評価指標として広く用いられている Fréchet Inception Distance (Heusel et al. 2017) が 2-Wasserstein 距離と関連があるため, 重要と言われている (Arsenyan et al. 2025).

データの内在次元について

- 現実世界のデータ分布はごく少数の変数で記述されると考えられている。これは多様体仮説と呼ばれ、機械学習の成功の基盤と考えられている (Pope et al. 2021)。
- データ分布を記述する上で必要な変数の数を、データ分布の**内在次元 (intrinsic dimension)** と呼ぶ。
- (Pope et al. 2021) は、MNIST、CIFAR-10、ImageNet などの代表的な画像データセットの内在次元推定を行った。
- 次元推定の結果、ImageNet では各画像が $224 \times 224 \times 3 = 15028$ の画素値を持つが、内在次元は 26 ~ 43 程度であるとされている。

内在次元を用いた拡散モデルの収束解析について

- データの内在次元を用いた拡散モデルの収束解析は (Huang et al. 2026; Azangulov et al. 2024; Li and Yan 2024) などによって行われており, (Huang et al. 2026) では $KL(p_{data}, \hat{p}) \leq O(k)$ の評価が得られている.
- 上記の結果は KL ダイバージェンスでの評価であり, 2-Wasserstein 距離での収束解析は (Huang et al. 2026) では Future Work とされている.
- 今回, (Huang et al. 2026) の評価方法を参考に 2-Wasserstein 距離での評価を行った.

拡散モデルの更新則

$X_0 \sim p_{data}$, $W \sim \mathcal{N}(0, I_d)$ として, 確率過程 $\{X_t\}_{t \in [0, T]}$ を次を満たすものとして定める.

$$X_t \stackrel{d}{=} \sqrt{1 - \sigma_t^2} X_0 + \sigma_t W \quad (\sigma_t = \sqrt{1 - e^{-2t}}, \quad t \in [0, T]) \quad (1)$$

X_t の密度関数を p_t とし, $s_t(x) := \nabla \log p_t(x)$ の推定量を $\hat{s}_t(x)$ として, データを生成する過程 $\{Y_n\}_{n=0,1,\dots,N}$ を次のように定義する.

$$Y_0 \sim \mathcal{N}(0, I_d),$$

$$Y_{n+1} = \frac{1}{\sqrt{\alpha_n}} (Y_n + (1 - \alpha_n) \hat{s}_{T-t_n}(Y_n)) + \sqrt{\frac{(1 - \alpha_n)(1 - \bar{\alpha}_{n+1})}{1 - \bar{\alpha}_n}} Z_n \quad (2)$$

ここで, $0 = t_0 < t_1 < \dots < t_N < t_{N+1} = T$, $\alpha_n = e^{-2(t_{n+1} - t_n)}$, $\bar{\alpha}_n = \prod_{i=n}^N \alpha_i$, $Z_n \stackrel{iid}{\sim} \mathcal{N}(0, I_d)$ である. 係数 α_n の値は (Ho et al. 2020) で提案された.

SDE を通じた解釈

前頁のアルゴリズムの時間を連続化することで SDE を使った解釈が可能である (Song et al. 2021) .

$$dX_t = -X_t dt + \sqrt{2} dW_t, \quad X_0 \sim p_{data}, \quad t \in [0, T] \quad (3)$$

の解 $\{X_t\}_{t \in [0, T]}$ に対して X_t の密度関数を p_t , $s_t(x) := \nabla \log p_t(x)$ として, 次の SDE を考える.

$$dY_t = (Y_t + 2s_{T-t}(Y_t))dt + \sqrt{2}dB_t \quad t \in [0, T] \quad (4)$$

$Y_0 \stackrel{d}{=} X_T$ としたとき, (4) の解を $\{Y_t\}_{t \in [0, T]}$ とすると, 任意の時刻 $t \in [0, T]$ において $Y_{T-t} \stackrel{d}{=} X_t$ が成立する (Anderson 1982).

Tweedie の公式

$\{X_t\}_{t \in [0, T]}$ を前頁の SDE の解として,

$$\mu_t(x) = \mathbb{E}[X_0 | X_t = x], \quad \Sigma_t(x) = \text{Cov}[X_0 | X_t = x] \quad (5)$$

とする. このとき, Tweedie の公式 (Efron 2011) より,

$$\mu_t(X_t) = \frac{1}{\sqrt{1 - \sigma_t^2}}(X_t + \sigma_t^2 \nabla \log p_t(X_t)) = \frac{1}{\sqrt{1 - \sigma_t^2}}(X_t + \sigma_t^2 s_t(X_t)) \quad (6)$$

が得られる. これを用いると, 前頁の時間を反転した SDE は次のように書ける.

$$dY_t = \left(Y_t + \frac{2\sqrt{1 - \sigma_{T-t}^2}}{\sigma_{T-t}^2} \mu_{T-t}(Y_t) - \frac{2}{\sigma_{T-t}^2} Y_t \right) dt + \sqrt{2} dB_t \quad (7)$$

$$= \left\{ \left(1 - \frac{2}{\sigma_{T-t}^2} \right) Y_t + \frac{2\sqrt{1 - \sigma_{T-t}^2}}{\sigma_{T-t}^2} \mu_{T-t}(Y_t) \right\} dt + \sqrt{2} dB_t \quad (8)$$

実際の生成アルゴリズムとの対応

前頁の (8) 式の SDE

$$dY_t = \left\{ \left(1 - \frac{2}{\sigma_{T-t}^2}\right) Y_t + \frac{2\sqrt{1 - \sigma_{T-t}^2}}{\sigma_{T-t}^2} \mu_{T-t}(Y_t) \right\} dt + \sqrt{2} dB_t \quad (9)$$

に対して, スコア関数の推定量を $\hat{s}$, $\hat{\mu}_t(x) = \frac{1}{\sqrt{1 - \sigma_t^2}}(x + \sigma_t^2 \hat{s}_t(x))$ として, $\{\hat{Y}_t\}_{t \in [0, T]}$ を, $\hat{Y}_0 \sim \mathcal{N}(0, I_d)$ であるような次の SDE の解とする.

$$d\hat{Y}_t = \left\{ \left(1 - \frac{2}{\sigma_{T-t}^2}\right) \hat{Y}_t + \frac{2\sqrt{1 - \sigma_{T-t}^2}}{\sigma_{T-t}^2} \hat{\mu}_{T-t_n}(\hat{Y}_{t_n}) \right\} dt + \sqrt{2} dB_t$$
$$(t \in (t_n, t_{n+1}]) \quad (10)$$

実際の生成アルゴリズムとの対応

前頁の $\{\hat{Y}_t\}_{t \in [0, T]}$ に対して, 次の定理が成立する.

Theorem

任意の $n = 0, \dots, N-1$ に対して, ある独立同分布で標準正規分布に従う $\{Z_n\}_{n=0, \dots, N-1}$ が存在して, 次の関係が成り立つ.

$$\hat{Y}_{t_{n+1}} = \frac{1}{\sqrt{\alpha_n}}(\hat{Y}_{t_n} + (1 - \alpha_n)\hat{s}_{T-t_n}(\hat{Y}_{t_n})) + \sqrt{\frac{(1 - \alpha_n)(1 - \bar{\alpha}_{n+1})}{1 - \bar{\alpha}_n}}Z_n \quad (11)$$

この定理により, (10) の SDE は (2) のアルゴリズムを連続時間補完したものと解釈できることがわかる.

データの内在次元の仮定について

データの内在次元を考えるために, 集合の複雑さに関する概念を定義する.

Definition

$A \subset \mathbb{R}^d$ に対する, スケール ϵ_0 における **covering number** $N^{\text{cover}}(A, |||_2, \epsilon_0)$ という値を, 次の関係を満たす $x_1, \dots, x_s \in \mathbb{R}^d$ が存在するような最小の自然数 s として定義する.

$$A \subset \bigcup_{i=1}^s B(x_i, \epsilon_0) \quad (12)$$

また, $\log N_{\text{cover}}(A, |||_2, \epsilon_0)$ を **metric entropy** という.

データの内在次元の仮定について

p_{data} のサポートを χ_{data} とする. (Li and Yan 2024; Huang et al. 2026) に従い, データの内在次元に関する 2 つの仮定を置く. 以下の k を χ_{data} の内在次元という.

仮定

$C_0 > 0$ を十分大きな定数とする. $\epsilon_0 = k^{-C_0}$ に対して, ある $C_{cover} > 0$ が存在して,

$$\log N_{cover}(\chi_{data}, \|\cdot\|_2, \epsilon_0) \leq C_{cover} k \log \frac{1}{\epsilon_0} \quad (13)$$

を満たすと仮定する.

仮定

ある定数 $C_R > 0$ が存在して, 次が成立すると仮定する.

$$\sup_{x \in \chi_{data}} \|x\|_2 \leq k^{C_R} \quad (14)$$

スコア関数に対する仮定

スコアの推定量に対してリプシッツ連続性の仮定を置く. この仮定はKLダイバージェンスの場合は課されていない. しかし, Wasserstein 距離での収束解析の先行研究では現状このような仮定が置かれている場合が多い.

仮定

ある二乗可積分な関数 $L : (0, 1) \rightarrow [0, \infty)$ が存在して, 次が成立する.

$$\|\hat{s}_t(x) - \hat{s}_t(y)\| \leq L(t)\|x - y\| \quad \forall (t, x, y) \in (0, 1) \times \mathbb{R}^d \times \mathbb{R}^d \quad (15)$$

次に, スコアの推定精度に関する仮定を置く. これはあらゆる拡散モデルの収束解析で課されているものであり, 学習の損失関数の形からも自然な仮定である.

仮定

$$\mathbb{E}[\|s_{T-t_n}(X_{T-t_n}) - \hat{s}_{T-t_n}(X_{T-t_n})\|_2^2] \leq \epsilon^2(t_i) < \infty \quad (0 \leq i \leq N-1) \quad (16)$$

定理

前頁までの仮定のもと, 次の評価が成立する.

Theorem

$\delta := T - t_N$ とし, κ を, $t_{n+1} - t_n \leq \kappa \min\{1, T - t_n\}$ ($0 \leq n \leq N-1$) を満たす最小の正数とする. このとき, ある定数 $C > 0$ が存在して, 次が成立する.

$$\begin{aligned} W_2(p_\delta, \mathcal{L}(\hat{Y}_{t_N})) &\leq e^{t_N+2\sum_{i=0}^{N-1} h_i L(T-t_i)} [\{e^{-2T} \mathbb{E}[\|X_0\|_2^2] + e^{-4T} d\}^{\frac{1}{2}} \\ &\quad + e^\kappa (1 - e^{-2\kappa}) \sum_{i=0}^{N-1} \epsilon(t_i) \\ &\quad + C\{\kappa \min\{\mathbb{E}[\|X_0\|_2^2], Tk \log k\} + \kappa^2 Nk \log k\}^{\frac{1}{2}}] \quad (17) \end{aligned}$$

証明の概要：同じ確率空間, 同じブラウン運動で比較する

- Y の初期分布を

$$Y_0 = e^{-T} X_0 + \sigma_T Z, \quad Z \sim \mathcal{N}(0, I_d) \quad (18)$$

と取る. このとき $Y_0 \stackrel{d}{=} X_T$ である.

- $\hat{Y}$ の初期分布を

$$\hat{Y}_0 = Z \quad (19)$$

とし, さらに Y_t と $\hat{Y}_t$ を同じブラウン運動 B_t で駆動する.

- このとき, Wasserstein 距離の定義から,

$$W_2(p_\delta, \mathcal{L}(\hat{Y}_{t_N})) \leq \mathbb{E} \left[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2 \right]^{1/2}. \quad (20)$$

となる.

証明の概要: $Y_{t_{n+1}} - \hat{Y}_{t_{n+1}}$ の計算

$Y_{t_{n+1}}, \hat{Y}_{t_{n+1}}$ は次のように書ける. ($h_n := t_{n+1} - t_n$ とする.)

$$\begin{aligned}\hat{Y}_{t_{n+1}} &= e^{-h_n} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-t_n}^2} \hat{Y}_{t_n} + \frac{e^{-(T-t_{n+1})}(1 - e^{-2h_n})}{\sigma_{T-t_n}^2} \hat{\mu}_{T-t_n}(\hat{Y}_{t_n}) \\ &\quad + \sqrt{2} \int_{t_n}^{t_{n+1}} e^{-(t_{n+1}-u)} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-u}^2} dB_u.\end{aligned}\tag{21}$$

$$\begin{aligned}Y_{t_{n+1}} &= e^{-h_n} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-t_n}^2} Y_{t_n} \\ &\quad + \int_{t_n}^{t_{n+1}} e^{-(t_{n+1}-u)} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-u}^2} \frac{2\sqrt{1 - \sigma_{T-u}^2}}{\sigma_{T-u}^2} \mu_{T-u}(Y_u) du \\ &\quad + \sqrt{2} \int_{t_n}^{t_{n+1}} e^{-(t_{n+1}-u)} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-u}^2} dB_u.\end{aligned}\tag{22}$$

証明の概要： $Y_{t_{n+1}} - \hat{Y}_{t_{n+1}}$ の計算

差を取り, 整理すると次のようになる.

$$\begin{aligned} Y_{t_{n+1}} - \hat{Y}_{t_{n+1}} &= e^{h_n}(Y_{t_n} - \hat{Y}_{t_n}) \\ &\quad + e^{h_n}(1 - e^{-2h_n}) \underbrace{\{s_{T-t_n}(Y_{t_n}) - \hat{s}_{T-t_n}(Y_{t_n})\}}_{\text{スコア推定誤差}} \\ &\quad + e^{h_n}(1 - e^{-2h_n}) \underbrace{\{\hat{s}_{T-t_n}(Y_{t_n}) - \hat{s}_{T-t_n}(\hat{Y}_{t_n})\}}_{\text{リプシッツ連続性で評価可能な誤差}} \\ &\quad + \int_{t_n}^{t_{n+1}} e^{-(t_{n+1}-u)} \frac{\sigma_{T-t_{n+1}}^2}{\sigma_{T-u}^2} \frac{2\sqrt{1 - \sigma_{T-u}^2}}{\sigma_{T-u}^2} \\ &\quad \times \underbrace{\{\mu_{T-u}(Y_u) - \mu_{T-t_n}(Y_{t_n})\}}_{\text{離散化誤差}} du \end{aligned} \tag{23}$$

証明の概要： $\mathbb{E}[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2]^{\frac{1}{2}}$ の評価につなげるための補題

Lemma ((Arsenyan et al. 2025))

非負数列 $(x_n)_{n \geq 0}$, $(B_n)_{n \geq 0}$, $(C_n)_{n \geq 0}$ と実数列 $(A_n)_{n \geq 0}$ が

$$x_{n+1}^2 \leq (e^{A_n} x_n + B_n)^2 + C_n^2 \quad (24)$$

を満たすとする. このとき, 任意の $n \geq 0$ に対して

$$\begin{aligned} x_{n+1} \leq & \exp\left(\sum_{i=0}^n A_i\right) x_0 + \sum_{j=0}^n \exp\left(\sum_{i=j+1}^n A_i\right) B_j \\ & + \left\{ \sum_{j=0}^n \exp\left(2 \sum_{i=j+1}^n A_i\right) C_j^2 \right\}^{\frac{1}{2}} \end{aligned} \quad (25)$$

が成立する.

証明の概要： $\mu_{T-t}(Y_t)$ のマルチンゲール性を使った誤差分解

$\mu_{T-t}(Y_t)$ は $\mathcal{F}_t := \sigma(Y_s, Z | 0 \leq s \leq t)$ に関してマルチンゲールであることに注意すると, (23) 式の最初の 3 項の和を S_n , 最後の項を R_n としたとき, S_n は $\mathcal{F}_{t_n}$ 可測であり, $\mathbb{E}[R_n | \mathcal{F}_{t_n}] = 0$ となることがわかる. よって,

$$\mathbb{E}[\langle S_n, R_n \rangle] = \mathbb{E}[\langle S_n, \mathbb{E}[R_n | \mathcal{F}_{t_n}] \rangle] = 0 \quad (26)$$

となる. よって,

$$\begin{aligned} \mathbb{E}[\|Y_{t_{n+1}} - \hat{Y}_{t_{n+1}}\|_2^2] &= \mathbb{E}[\|S_n + R_n\|_2^2] \\ &= \mathbb{E}[\|S_n\|_2^2] + \mathbb{E}[\|R_n\|_2^2] + 2\mathbb{E}[\langle S_n, R_n \rangle] \\ &= \mathbb{E}[\|S_n\|_2^2] + \mathbb{E}[\|R_n\|_2^2] \end{aligned} \quad (27)$$

証明の概要： $\mathbb{E}[\|S_n\|_2^2]$ の評価

$$\begin{aligned} S_n &= e^{h_n}(Y_{t_n} - \hat{Y}_{t_n}) \\ &\quad + e^{h_n}(1 - e^{-2h_n}) \underbrace{\{s_{T-t_n}(Y_{t_n}) - \hat{s}_{T-t_n}(Y_{t_n})\}}_{\text{スコア推定誤差}} \\ &\quad + e^{h_n}(1 - e^{-2h_n}) \underbrace{\{\hat{s}_{T-t_n}(Y_{t_n}) - \hat{s}_{T-t_n}(\hat{Y}_{t_n})\}}_{\text{リプシッツ連続性で評価可能な誤差}} \end{aligned} \quad (28)$$

に対して、仮定と三角不等式を用いると、

$$\begin{aligned} \mathbb{E}[\|S_n\|_2^2]^{\frac{1}{2}} &\leq e^{h_n} \{1 + L(T - t_n)(1 - e^{-2h_n})\} \left(\mathbb{E} \|Y_{t_n} - \hat{Y}_{t_n}\|_2^2 \right)^{1/2} \\ &\quad + e^{h_n}(1 - e^{-2h_n})\epsilon(t_n). \end{aligned} \quad (29)$$

が得られる.

証明の概要：補題を適用する

前頁の評価により,

$$\begin{aligned}\mathbb{E}\|Y_{t_{n+1}} - \hat{Y}_{t_{n+1}}\|_2^2 &\leq \left[e^{h_n} \{1 + L(T - t_n)(1 - e^{-2h_n})\} \right. \\ &\quad \times \mathbb{E} \left[\|Y_{t_n} - \hat{Y}_{t_n}\|_2^2 \right]^{1/2} \\ &\quad \left. + e^{h_n}(1 - e^{-2h_n})\epsilon(t_n) \right]^2 + \mathbb{E}[\|R_n\|_2^2] \quad (30)\end{aligned}$$

が得られる. ここに

$$\begin{aligned}x_n &= \mathbb{E}[\|Y_{t_n} - \hat{Y}_{t_n}\|_2^2]^{\frac{1}{2}}, & A_n &= h_n + \log\{1 + L(T - t_n)(1 - e^{-2h_n})\}, \\ B_n &= e^{h_n}(1 - e^{-2h_n})\epsilon(t_n), & C_n &= \mathbb{E}[\|R_n\|_2^2]^{\frac{1}{2}}\end{aligned} \quad (31)$$

とすることで補題が適用できる.

証明の概要：補題を適用する

補題より,

$$\begin{aligned} \mathbb{E} \left[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2 \right]^{1/2} &\leq \left(\prod_{i=0}^{N-1} e^{h_i} \{1 + L(T - t_i)(1 - e^{-2h_i})\} \right) \\ &\quad \times \left[\mathbb{E} \left[\|Y_0 - \hat{Y}_0\|_2^2 \right]^{1/2} \right. \\ &\quad \left. + \sum_{j=0}^{N-1} e^{h_j} (1 - e^{-2h_j}) \epsilon(t_j) + \left(\sum_{j=0}^{N-1} \mathbb{E}[\|R_j\|_2^2] \right)^{1/2} \right] \\ &\leq e^{t_N + 2 \sum_{i=0}^{N-1} h_i L(T - t_i)} \\ &\quad \times \left[\mathbb{E} \left[\|Y_0 - \hat{Y}_0\|_2^2 \right]^{1/2} + e^{\kappa} (1 - e^{-2\kappa}) \sum_{j=0}^{N-1} \epsilon(t_j) \right. \\ &\quad \left. + \left(\sum_{j=0}^{N-1} \mathbb{E}[\|R_j\|_2^2] \right)^{1/2} \right]. \end{aligned} \tag{32}$$

証明の概要：初期分布誤差を評価

初期値の取り方より

$$Y_0 - \hat{Y}_0 = e^{-T} X_0 + (\sigma_T - 1)Z. \quad (33)$$

よって, X_0 と Z が独立であることから,

$$\mathbb{E} \left[\|Y_0 - \hat{Y}_0\|_2^2 \right] \leq e^{-2T} \mathbb{E} \left[\|X_0\|_2^2 \right] + (1 - \sigma_T)^2 d. \quad (34)$$

また,

$$(1 - \sigma_T)^2 = \left(1 - \sqrt{1 - e^{-2T}} \right)^2 \leq e^{-4T} \quad (35)$$

なので,

$$\mathbb{E} \left[\|Y_0 - \hat{Y}_0\|_2^2 \right] \leq e^{-2T} \mathbb{E} \left[\|X_0\|_2^2 \right] + e^{-4T} d. \quad (36)$$

証明の概要：離散化誤差を評価

(Huang et al. 2026) より, 次の評価が得られる.

$$\sum_{n=0}^{N-1} \mathbb{E} \|R_n\|_2^2 \leq C \{ \kappa \min\{\mathbb{E} \|X_0\|_2^2, Tk \log k\} + \kappa^2 Nk \log k \} \quad (37)$$

これは主に, 次の2つの補題から得られる.

Lemma

$$\mathbb{E} [\|\mu_{T-t}(Y_t) - \mu_{T-s}(Y_s)\|_2^2] = \mathbb{E} [\text{Tr}(\Sigma_{T-s}(Y_s))] - \mathbb{E} [\text{Tr}(\Sigma_{T-t}(Y_t))] \quad (38)$$

Lemma

ある定数 $C > 0$ が存在して,

$$\mathbb{E} [\text{Tr}(\Sigma_{T-t}(Y_t))] \leq C \min \left\{ \mathbb{E} \|X_0\|_2^2, \frac{\sigma_{T-t}^2}{1 - \sigma_{T-t}^2} k \log k \right\} \quad (39)$$

証明の概要：最後の評価

前頁までの評価をまとめると,

$$\begin{aligned}\mathbb{E} \left[\|Y_{t_N} - \hat{Y}_{t_N}\|_2^2 \right]^{1/2} &\leq e^{t_N + 2 \sum_{i=0}^{N-1} h_i L(T-t_i)} [\{e^{-2T} \mathbb{E}[\|X_0\|_2^2] + e^{-4T} d\}^{\frac{1}{2}} \\ &\quad + e^{\kappa}(1 - e^{-2\kappa}) \sum_{i=0}^{N-1} \epsilon(t_i) \\ &\quad + C\{\kappa \min\{\mathbb{E}[\|X_0\|_2^2], Tk \log k\} + \kappa^2 Nk \log k\}^{\frac{1}{2}}] \quad (40)\end{aligned}$$

が得られる.

参考文献 I

- Benton, J., De Bortoli, V., Doucet, A. and Deligiannidis, G. (2024). Nearly d -linear convergence bounds for diffusion models via stochastic localization. In *International Conference on Learning Representations*.
https://proceedings.iclr.cc/paper_files/paper/2024/hash/9edce07129d2ec4c511a8783eb3d81b5-Abstract-Conference.html
- Huang, Z., Wei, Y. and Chen, Y. (2024; revised 2026). Denoising diffusion probabilistic models are optimally adaptive to unknown low dimensionality. <https://arxiv.org/abs/2410.18784>
- Chen, H., Lee, H. and Lu, J. (2023). Improved analysis of score-based generative modeling: user-friendly bounds under minimal smoothness assumptions. In *Proceedings of the 40th International Conference on Machine Learning*.
<https://proceedings.mlr.press/v202/chen23q.html>

参考文献 II

- Anderson, B. D. O. (1982). Reverse-time diffusion equation models. *Stochastic Process. Appl.* 12 313 – 326.
<https://mathscinet.ams.org/mathscinet/article?mr=656280>
- Hausmann, U. G. and Pardoux, E. (1986). Time reversal of diffusions. *Ann. Probab.* 14 1188 – 1205.
<https://mathscinet.ams.org/mathscinet/article?mr=866342>
- Wenpin Tang and Hanyang Zhao (2024). Score-based Diffusion Models via Stochastic Differential Equations – a Technical Tutorial.
<https://arxiv.org/abs/2402.07487>
- Efron, B. (2011). Tweedie's formula and selection bias. *Journal of the American Statistical Association* 106(496), 1602–1614.
<https://doi.org/10.1198/jasa.2011.tm11181>

参考文献 III

- Chen, S., Chewi, S., Li, J., Li, Y., Salim, A. and Zhang, A. R. (2023). Sampling is as easy as learning the score: theory for diffusion models with minimal data assumptions.
<https://arxiv.org/abs/2209.11215>
- Borji, A. (2019). Pros and cons of GAN evaluation measures. *Comput. Vis. Image Underst.* 179 41 – 65. <https://arxiv.org/abs/1802.03446>
- Koike, Y. (2026). A note on connections between the Föllmer process and the denoising diffusion probabilistic model. arXiv preprint arXiv:2605.18040. <https://arxiv.org/abs/2605.18040>
- Arsenyan, V., Vardanyan, E. and Dalalyan, A. S. (2025). Assessing the quality of denoising diffusion models in Wasserstein distance: noisy score and optimal bounds. In *Advances in Neural Information Processing Systems* 38. https://proceedings.neurips.cc/paper_files/paper/2025/hash/1c26c389d60ec419fd24b5fee5b35796-Abstract-Conference.html

参考文献 IV

- Beyler, E. and Bach, F. (2025). Convergence of deterministic and stochastic diffusion-model samplers: a simple analysis in Wasserstein distance. arXiv preprint arXiv:2508.03210.
<https://arxiv.org/abs/2508.03210>
- Bruno, S. and Sabanis, S. (2025). Wasserstein convergence of score-based generative models under semiconvexity and discontinuous gradients. *Transactions on Machine Learning Research*.
<https://openreview.net/forum?id=vS9iVRB7XF>
- Gao, X., Nguyen, H. M. and Zhu, L. (2025). Wasserstein convergence guarantees for a general class of score-based generative models. *Journal of Machine Learning Research* 26(43), 1–54.
<https://jmlr.org/papers/v26/24-0902.html>

Gentiloni Silveri, M. and Ocello, A. (2025). Beyond log-concavity and score regularity: improved convergence bounds for score-based generative models in W_2 -distance. In *Proceedings of the 42nd International Conference on Machine Learning*, Proceedings of Machine Learning Research 267, 55631–55656.

<https://proceedings.mlr.press/v267/silveri25a.html>

Pfarr, E., Timofte, R. and Werner, F. (2026). Analyzing the error of generative diffusion models: from Euler–Maruyama to higher-order schemes. arXiv preprint arXiv:2601.18425.

<https://arxiv.org/abs/2601.18425>

Strasman, S., Ocello, A., Boyer, C., Le Corff, S. and Lemaire, V. (2025). An analysis of the noise schedule for score-based generative models. *Transactions on Machine Learning Research*.

<https://openreview.net/forum?id=BlYIPa0Fx1>

参考文献 VI

- Yu, Y. and Yu, L. (2025). Advancing Wasserstein convergence analysis of score-based models: insights from discretization and second-order acceleration. In *Advances in Neural Information Processing Systems 38*.
https://proceedings.neurips.cc/paper_files/paper/2025/hash/c9d9659d1d960b53e8121469ef1f2df5-Abstract-Conference.html
- D. Bakry, I. Gentil, and M. Ledoux. Analysis and geometry of Markov diffusion operators. Vol. 348. Grundlehren der Mathematischen Wissenschaften [Fundamental Principles of Mathematical Sciences]. Springer, Cham, 2014, pp. xx+552.
<https://link.springer.com/book/10.1007/978-3-319-00227-9>
- Azangulov, I., Deligiannidis, G. and Rousseau, J. (2024). Convergence of diffusion models under the manifold hypothesis in high dimensions. arXiv preprint arXiv:2409.18804. <https://arxiv.org/abs/2409.18804>

参考文献 VII

- Ho, J., Jain, A. and Abbeel, P. (2020). Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems 33*, 6840–6851. <https://proceedings.neurips.cc/paper/2020/hash/4c5bcfec8584af0d967f1ab10179ca4b-Abstract.html>
- Li, G. and Yan, Y. (2024). Adapting to unknown low-dimensional structures in score-based diffusion models. In *Advances in Neural Information Processing Systems 37*. https://proceedings.neurips.cc/paper_files/paper/2024/hash/e46c303cfd3b93bd32ecf6070318efc3-Abstract-Conference.html
- Pope, P., Zhu, C., Abdelkader, A., Goldblum, M. and Goldstein, T. (2021). The intrinsic dimension of images and its impact on learning. In *International Conference on Learning Representations*. <https://openreview.net/forum?id=XJk19XzGq2J>

参考文献 VIII

- Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B. and Hochreiter, S. (2017). GANs trained by a two time-scale update rule converge to a local Nash equilibrium. In *Advances in Neural Information Processing Systems 30*. <https://proceedings.neurips.cc/paper/2017/hash/8a1d694707eb0fefe65871369074926d-Abstract.html>
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S. and Poole, B. (2021). Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*. <https://openreview.net/forum?id=PxTIG12RRHS>